

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Machine Learning Engineering



Caso de Estudio 2

MCDONALD'S

*Documento Anexo: Propuesta de Integración de Modelos de ML, AI
y LLM en el Pipeline de Datos*

Francis Aguilar 22243

Paula Barillas 22764

Bianca Calderón 22272

José Marchena, 22398

Gerardo Pineda 22880

Mónica Salvatierra 22249

Propuesta de ML, AI y LLM

MyMcDonald's Rewards — Machine Learning Engineering (CC3105)

1. Objetivo

Este documento propone puntos concretos de integración de Machine Learning, Inteligencia Artificial y Modelos de Lenguaje (LLM) sobre la arquitectura de datos diagnosticada para el sistema de puntos MyMcDonald's Rewards, con el fin de pasar de un pipeline puramente transaccional (registrar y sumar puntos) a uno que también genere valor de negocio mediante retención, personalización y eficiencia operativa.

2. Punto de inserción en el pipeline

Todos los modelos propuestos se alimentan de la capa Gold del data lake (saldo de puntos, historial de transacciones y variables RFM por cliente), generada después del motor de reglas de puntos. Esto asegura que los modelos consuman datos ya limpios, deduplicados y con las reglas de negocio aplicadas, evitando que un modelo aprenda de datos crudos con ruido o de transacciones excluidas (por ejemplo, delivery de terceros).

Las predicciones y recomendaciones generadas por los modelos regresan al pipeline como una nueva fuente de datos hacia el motor de personalización y hacia el CRM, cerrando el ciclo: dato transaccional → modelo → acción de negocio → nuevo dato transaccional.

3. Casos de uso propuestos

Caso de uso	Tipo de modelo	Variables de entrada (capa Gold)	Valor de negocio
Predicción de abandono (Churn)	Clasificación (Gradient Boosting / XGBoost)	Recencia, frecuencia, ticket promedio, canal preferido	Campañas de retención automatizadas antes de que el cliente deje de usar la app
Recomendación de canje / producto	Sistema de recomendación (filtrado colaborativo o embeddings)	Historial de canjes, saldo actual, preferencias por horario/menú	Aumenta el uso de puntos y la frecuencia de visita
Predicción de demanda por restaurante	Series de tiempo (Prophet / LightGBM)	Transacciones históricas por restaurante y canal	Optimiza inventario y dotación de personal
Detección de fraude en puntos	Detección de anomalías (Isolation Forest)	Velocidad de canje, patrones atípicos de acumulación	Protege la integridad del saldo de puntos
Asistente conversacional (LLM)	LLM con recuperación de contexto (RAG)	FAQ del programa, saldo del cliente, catálogo de canje	Reduce fricción de soporte y resuelve dudas sobre el programa 24/7

4. Priorización recomendada

Dado el horizonte de una semana para el diagnóstico y la necesidad de mostrar valor rápido al cliente, se recomienda la siguiente secuencia de implementación:

Fase 1 (quick win): Recomendación de canje

Es el modelo de menor complejidad técnica (no requiere infraestructura de streaming ni GPUs) y tiene impacto directo y medible en la frecuencia de uso de puntos, una de las métricas que McDonald's ya reporta públicamente como objetivo del programa.

Fase 2: Predicción de abandono (churn)

Reutiliza las mismas variables RFM ya calculadas en la capa Gold para el caso anterior, por lo que el costo incremental de desarrollo es bajo una vez implementada la Fase 1.

Fase 3: Asistente conversacional (LLM/RAG)

Se recomienda posponerlo hasta que la capa de gobierno de datos (control de PII, catálogo) esté madura, ya que el asistente necesitará acceso controlado al saldo y al historial del cliente en tiempo de conversación.

Fase 4: Detección de fraude y predicción de demanda

Casos de uso de mayor especialización (series de tiempo por restaurante, detección de anomalías) que pueden desarrollarse en paralelo una vez el pipeline central sea estable, pero no son bloqueantes para el lanzamiento de las fases anteriores.

5. Consideraciones de gobierno y riesgo

- Todo modelo que use datos de comportamiento del cliente debe respetar las políticas de privacidad y consentimiento ya vigentes para el uso de la app.
- Los modelos de recomendación y el LLM conversacional deben registrar sus predicciones y respuestas para auditoría, dado que interactúan directamente con el cliente final.
- Se recomienda monitoreo de drift sobre las variables RFM, ya que cambios en las reglas del programa (por ejemplo, ajustes en la vigencia de puntos) alteran la distribución de esas variables y pueden degradar los modelos sin previo aviso.

6. Conclusión

La arquitectura de datos ya diagnosticada tiene todo lo necesario en su capa Gold para soportar estos casos de uso sin rediseñar el pipeline transaccional: basta con exponer esa capa como fuente de features para los modelos y cerrar el ciclo con el motor de personalización existente. Se recomienda iniciar con el motor de recomendación de canje como prueba de concepto de mayor escala, dado su bajo riesgo técnico y su relación directa con las métricas de negocio que McDonald's ya utiliza para medir el éxito del programa.